

TEST TECHNIQUE – TRAITEMENT DU LANGAGE NATUREL (NLP):

Classification de commentaires citoyens sur les services publics

Projet : **Sélection des participants de TAISS 2026 pour stage à Afriklang**

Septembre 2026



RÉPUBLIQUE TOGOLAISE

Ministère de l'Efficacité du Service Public
et de la Transformation Numérique

Togo Data Lab

SOMMAIRE

Informations pratiques.....	3
Contexte.....	3
Description du dataset fourni.....	3
Travail demandé.....	3
Grille d'évaluation.....	5
Barème de décision.....	6

Informations pratiques

- **Restitution** : Vendredi à 02 Octobre 2026 à **10h**.
- **Rendu** : un notebook Jupyter (.ipynb) + un fichier README.md déposés sur un dépôt GitHub public
- **Lien GitHub à envoyer à** : contact@datalab.gouv.tg
- **Langage** : Python uniquement
- **Ressources autorisées** : documentation officielle, bibliothèques open source, internet; mais le code doit être le vôtre

Contexte

Afriklang est une startup spécialisée dans le développement de solutions NLP appliquées aux langues et contextes africains. Dans le cadre de sa participation à TAISS 2026, Afriklang a sollicité notre équipe pour identifier et recommander les meilleurs profils Data Science issus de la Togo AI Summer School 2026 (TAISS 2026).

Ce test technique s'inscrit dans ce processus de sélection. Il évalue votre capacité à construire un pipeline NLP complet; du nettoyage des données jusqu'à l'interprétation des résultats, sur un jeu de données représentatif des projets réels portés par Afriklang : traitement de retours citoyens sur les services publics, rédigés majoritairement en français avec des insertions occasionnelles de termes en ewé ou en mina.

Les meilleurs candidats seront recommandés directement à Afriklang pour intégrer leur équipe dans le cadre d'un stage non payant de 3 mois en remote.

Description du dataset fourni

Fichier : `dataset_nlp_test_tal.csv`

Le dataset contient 150 commentaires citoyens équilibrés en 3 catégories :

- Satisfaction — retours positifs sur les services publics
- Insatisfaction — plaintes et expériences négatives
- Suggestion — propositions d'amélioration des services

Colonnes :

- **id** : identifiant unique de chaque commentaire
- **texte** : le commentaire citoyen en texte brut
- **categorie** : la classe cible (Satisfaction / Insatisfaction / Suggestion)

Travail demandé

Partie 1 — Exploration & Prétraitement des données (30 pts)

1.1 Chargement et exploration

- Chargez le dataset et affichez sa structure (shape, types, exemples)
- Visualisez la distribution des classes

- Calculez la longueur moyenne des textes par catégorie

1.2 Nettoyage du texte

- Mettez les textes en minuscules
- Supprimez la ponctuation, les chiffres et les caractères spéciaux
- Gérez les mots en éwé/mina présents dans certains commentaires (à vous de décider de la stratégie)
- Supprimez les stopwords français (justifiez votre liste de stopwords)

1.3 Visualisations

- Générez un nuage de mots (wordcloud) par catégorie
- Affichez les 15 termes les plus fréquents par catégorie

Partie 2 — Modélisation (40 pts)

2.1 Vectorisation

- Choisissez et justifiez votre méthode de vectorisation (TF-IDF, CountVectorizer, embeddings, etc.)
- Divisez le dataset en ensemble d'entraînement (80%) et de test (20%) — fixez un random_state

2.2 Entraînement

- Entraînez au minimum 2 algorithmes de classification différents
- Exemples : Logistic Regression, SVM, Random Forest, Naive Bayes, KNN...

2.3 Évaluation

- Calculez pour chaque modèle : Accuracy, F1-score macro, matrice de confusion
- Comparez les modèles dans un tableau de synthèse
- Identifiez et analysez 3 à 5 exemples mal classés : pourquoi le modèle s'est-il trompé ?

Partie 3 — Qualité du code & restitution (30 pts)

- Le notebook doit être structuré en sections claires avec des titres et des commentaires
- Le code doit être lisible, sans répétitions inutiles, avec des noms de variables explicites
- Un fichier requirements.txt (ou environment.yml) doit permettre de reproduire l'environnement
- Le README.md doit expliquer en 10 à 15 lignes votre approche, vos choix et vos résultats
- Concluez en identifiant les limites de votre approche et en proposant au moins 2 pistes d'amélioration

Bonus (hors barème — pour se distinguer)

- Tentez un fine-tuning d'un modèle pré-entraîné multilingue (CamemBERT, mBERT, XLM-R) sur ce dataset
- Proposez une interface simple (Streamlit, Gradio) permettant de tester votre modèle sur un nouveau texte
- Gérez spécifiquement les commentaires mixtes français/éwé-mina pour améliorer les performances

Grille d'évaluation

Critère	Détail	Points
PARTIE 1 — Exploration & Prétraitement		/ 30
Chargement & aperçu des données	Chargement correct, affichage shape, distribution des classes, exemples par catégorie	5
Nettoyage du texte	Suppression des caractères spéciaux, mise en minuscules, gestion des accents et mots éwé/mina	8
Tokenisation & stopwords	Suppression des stopwords français, tokenisation adaptée au contexte multilingue	7
Visualisations	Nuage de mots par catégorie, distribution des longueurs de texte, fréquence des termes	10
PARTIE 2 — Modélisation		/ 40
Vectorisation	Choix justifié entre TF-IDF / CountVectorizer / embeddings simples	8
Entraînement du modèle	Split train/test (ex. 80/20), entraînement d'au moins 2 algorithmes (ex. Logistic Regression, SVM, Random Forest)	12
Évaluation	Accuracy, F1-score macro, matrice de confusion commentée	12
Analyse des erreurs	Identification des exemples mal classés et hypothèses sur les causes	8
PARTIE 3 — Qualité du code & restitution		/ 30
Lisibilité du code	Code commenté, structuré en sections claires, noms de variables explicites	10
Reproductibilité	Seed fixé, instructions d'installation claires (requirements.txt ou conda env)	8
Interprétation & conclusion	Analyse des résultats, limites identifiées, pistes d'amélioration proposées	12
TOTAL		/ 100

Barème de décision

Score	Appréciation	Décision
≥ 80	Excellent	Convoqué en entretien (prioritaire)
65 - 79	Bon	Convoqué en entretien
50 - 64	Passable	Selon disponibilité des places
< 50	Insuffisant	Non retenu
